
Otimização de Rotas de Patrulhamento com Drones: Um Estudo Comparativo de Meta-heurísticas Bioinspiradas

Heitor Freitas



UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE COMPUTAÇÃO
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Uberlândia
2026

Heitor Freitas

**Otimização de Rotas de Patrulhamento com
Drones: Um Estudo Comparativo de
Meta-heurísticas Bioinspiradas**

Trabalho de Conclusão de Curso apresentado à
Faculdade de Computação da Universidade Fe-
deral de Uberlândia, como parte dos requisitos
exigidos para a obtenção título de Bacharel em
Ciência da Computação.

Área de concentração: Ciência da Computação

Orientador: Dr. Claudiney Ramos Tinoco

Uberlândia
2026

Aos meus pais, pelo apoio incondicional.

Agradecimentos

Ao Prof. Dr. Claudiney Ramos Tinoco, pela orientação e pelo incentivo ao longo deste trabalho. Aos colegas de curso, pelas discussões e pelo apoio durante a graduação.

“Otimização é a arte de encontrar a melhor resposta possível dentro do que é computacionalmente viável.”

Resumo

Este trabalho investiga a otimização de rotas de patrulhamento com drones por meio do TSP-SD-ATP, uma variante do Problema do Caixeiro Viajante em que o custo de transição depende da sequência de visita. O custo entre pontos soma distância euclidiana e penalidade angular calculada a partir do nó anterior, do nó atual e do próximo nó, representada por um tensor tridimensional. Foram implementados e comparados Algoritmo Genético, Otimização por Enxame de Partículas, Otimização por Colônia de Formigas, busca exaustiva e um lower bound por relaxação do problema de designação. Os experimentos totalizaram 4638 execuções registradas em arquivos de resumo, evolução e tempo, cobrindo 30 instâncias de 10 a 100 pontos e 51 sementes por meta-heurística. Nas 18 instâncias com ótimo por busca exaustiva, ACO obteve gap médio de 0,4296%, contra 5,2814% do GA e 22,2915% do PSO. Em instâncias de 100 pontos, ACO manteve menor makespan médio, mas exigiu cerca de 4,26 s de otimização, enquanto GA ficou abaixo de 40 ms. Os resultados indicam um trade-off claro: ACO produziu rotas de melhor qualidade no desenho experimental, GA foi muito mais rápido e PSO teve desempenho inferior com a codificação por random keys.

Palavras-chave: Otimização Combinatória. Problema do Caixeiro Viajante. Meta-heurísticas Bioinspiradas. Patrulhamento com Drones..

Abstract

This work investigates drone patrol route optimization through the TSP-SD-ATP, a Traveling Salesman Problem variant in which transition costs depend on the visit sequence. The cost between points combines Euclidean distance and an angular penalty computed from the previous, current, and next nodes, represented by a three-dimensional tensor. We implemented and compared a Genetic Algorithm, Particle Swarm Optimization, Ant Colony Optimization, exhaustive search, and an assignment-problem lower bound. The experiments produced 4638 structured summary, evolution, and timing files, covering 30 instances from 10 to 100 points and 51 seeds per metaheuristic. On the 18 instances with exhaustive-search optima, ACO achieved an average gap of 0.4296%, compared with 5.2814% for GA and 22.2915% for PSO. On 100-point instances, ACO kept the lowest average makespan, but required about 4.26 s of optimization, whereas GA remained below 40 ms. The results show a clear trade-off: ACO produced the highest-quality routes in the experimental design, GA was much faster, and PSO performed worse with the random-key encoding.

Keywords: Combinatorial Optimization. Traveling Salesman Problem. Bio-inspired Metaheuristics. Drone Patrol..

Lista de ilustrações

Figura 1 – Penalidade angular calculada a partir de três nós consecutivos da rota. Fonte: elaborado pelo autor.	26
Figura 2 – Representação do tensor 3D de custos usado para avaliar transições dependentes da sequência. Fonte: elaborado pelo autor.	32
Figura 3 – Gap em relação à busca exaustiva nas instâncias com ótimo conhecido. Fonte: dados de ‘src/data/results/'.	37
Figura 4 – Taxa de acerto do ótimo por método nas instâncias pequenas. Fonte: dados de ‘src/data/results/'.	38
Figura 5 – Makespan mediano por instância e método nas 30 instâncias avaliadas. Fonte: dados de ‘src/data/results/'.	39
Figura 6 – Escalabilidade temporal dos métodos por tamanho de instância. Fonte: dados de ‘src/data/results/timing/'.	41
Figura 7 – Trade-off entre qualidade de solução e tempo de otimização. Fonte: dados de ‘src/data/results/'.	41
Figura 8 – Distribuição do makespan por método e tamanho, considerando as se- mentes estocásticas. Fonte: dados de ‘src/data/results/'.	42
Figura 9 – Comportamento agregado de convergência dos métodos ao longo das execuções. Fonte: dados de evolução em ‘src/data/results/evolution/'.	43
Figura 10 – Diagrama de diferença crítica para os ranks médios de makespan. Fonte: ‘scripts/analise-estatistica.py’.	43

Lista de tabelas

Tabela 1	– Métodos implementados e parâmetros usados nos experimentos.	34
Tabela 2	– Cobertura experimental dos métodos avaliados.	36
Tabela 3	– Ótimos obtidos por busca exaustiva nas 18 instâncias pequenas.	36
Tabela 4	– Gap percentual em relação ao ótimo nas instâncias ‘10a’–‘15c’.	37
Tabela 5	– Melhor e média de makespan nas instâncias de 50 e 100 pontos.	40
Tabela 6	– Resumo do gap entre lower bound AP e ótimo por busca exaustiva. . .	40
Tabela 7	– Tempo médio de otimização em instâncias de 100 pontos.	40

Lista de siglas

Sumário

1	INTRODUÇÃO	21
1.1	Motivação	21
1.2	Objetivos e Desafios da Pesquisa	22
1.3	Hipótese	23
1.4	Contribuições	23
1.5	Organização da Dissertação ou Tese	24
2	FUNDAMENTAÇÃO TEÓRICA	25
2.1	Problema do Caixeiro Viajante	25
2.2	Custos Dependentes da Sequência	26
2.3	Roteamento de Drones e Variantes do TSP	27
2.4	Busca Exaustiva	27
2.5	Algoritmos Genéticos	27
2.6	Otimização por Enxame de Partículas	28
2.7	Otimização por Colônia de Formigas	28
2.8	Limitantes Inferiores e Relaxação por Designação	28
2.9	Estudos Comparativos	29
3	PROPOSTA	31
3.1	Formulação do Problema	31
3.2	Arquitetura da Implementação	31
3.3	Algoritmo Genético	32
3.4	Otimização por Enxame de Partículas	33
3.5	Otimização por Colônia de Formigas	33
3.6	Busca Exaustiva	33
3.7	Lower Bound por Relaxação AP	34
3.8	Pipeline Experimental	34

4	EXPERIMENTOS E ANÁLISE DOS RESULTADOS	35
4.1	Método para a Avaliação	35
4.2	Experimentos	36
4.3	Avaliação dos Resultados	36
4.3.1	Qualidade nas Instâncias com Ótimo Conhecido	36
4.3.2	Qualidade nas Instâncias Maiores	38
4.3.3	Lower Bound AP	40
4.3.4	Tempo Computacional	40
4.3.5	Estabilidade e Convergência	42
4.3.6	Análise Estatística	42
4.3.7	Limitações Metodológicas	43
5	CONCLUSÃO	45
5.1	Principais Contribuições	45
5.2	Limitações	46
5.3	Trabalhos Futuros	46
5.4	Contribuições em Produção Bibliográfica	47
	REFERÊNCIAS	49

APÊNDICES	53
------------------	-----------

ANEXOS	55
---------------	-----------

Introdução

Missões de patrulhamento com drones exigem que um conjunto de pontos de interesse seja visitado de forma eficiente, recorrente e com tempo de deslocamento reduzido. Em aplicações de inspeção, vigilância ambiental e monitoramento de infraestrutura, a qualidade de uma rota não depende apenas da distância total percorrida. Curvas bruscas podem aumentar o tempo de voo, o consumo de energia e a dificuldade de execução da trajetória. Esse detalhe operacional torna insuficiente uma modelagem que trate cada deslocamento apenas como uma aresta independente entre dois pontos.

O Problema do Caixeiro Viajante (*Traveling Salesman Problem*, TSP) fornece uma abstração clássica para rotas que partem de uma origem, visitam todos os pontos exatamente uma vez e retornam à origem (LAWLER et al., 1985; APPLEGATE et al., 2006). A versão de decisão do TSP é NP-completa (GAREY; JOHNSON, 1979); por isso, a enumeração completa das rotas deixa de ser prática à medida que o número de pontos cresce. Essa dificuldade justifica o uso de heurísticas e meta-heurísticas quando a meta é obter boas soluções em tempo computacional controlado.

Este trabalho estuda uma variante do TSP motivada por patrulhamento aéreo com drones: o TSP com penalidades angulares dependentes da sequência, chamado aqui de TSP-SD-ATP (*Traveling Salesman Problem with Sequence-Dependent Angular Turn Penalties*). Nessa formulação, o custo de seguir de um ponto atual para um próximo ponto depende também do ponto visitado imediatamente antes. A instância deixa de ser representada por uma matriz bidimensional de arestas e passa a usar um tensor tridimensional de custos, indexado por nó anterior, nó atual e próximo nó. O objetivo é minimizar o *makespan*, definido como o tempo/custo total da rota iniciada e encerrada na base.

1.1 Motivação

O roteamento com drones tem recebido atenção em diferentes formulações. Murray e Chu (MURRAY; CHU, 2015) introduziram o *Flying Sidekick Traveling Salesman Problem*, no qual caminhão e drone cooperam em entregas. Agatz, Bouman e Schmidt (AGATZ;

BOUMAN; SCHMIDT, 2018) estudaram o TSP com drone por meio de formulações e heurísticas, enquanto Dell’Amico et al. (DELL’AMICO; MONTEMANNI; NOVELLANI, 2021; DELL’AMICO; MONTEMANNI; NOVELLANI, 2022) avançaram variantes com múltiplos drones e métodos exatos. No contexto de patrulha, Rajan, Sundar e Gautam (RAJAN; SUNDAR; GAUTAM, 2022) modelaram missões de VANTs com horizonte finito e decisões recorrentes de visita.

Esses trabalhos mostram que pequenas alterações operacionais geram variantes distintas do TSP. O problema investigado nesta monografia não combina caminhão e drone nem modela múltiplos veículos; ele isola o caso de um único drone que deve visitar todos os pontos de interesse e retornar à base. A contribuição está em avaliar o impacto de uma função de custo dependente da sequência, na qual a transição anterior–atual–próximo incorpora distância euclidiana e penalidade angular.

A literatura contém comparações entre Algoritmo Genético (GA), Otimização por Enxame de Partículas (PSO) e Otimização por Colônia de Formigas (ACO) no TSP clássico e em variantes próximas (WU, 2020; HAROUN; JAMAL; HICHAM, 2015; CHANDRA; NARO, 2022; HALIM; ISMAIL, 2019). Na revisão realizada para este trabalho, não foram identificados estudos que comparem sistematicamente esses três métodos especificamente no TSP-SD-ATP. Essa lacuna motiva uma avaliação experimental controlada, com a mesma função objetivo, as mesmas instâncias e registros estruturados de qualidade, evolução e tempo de execução.

1.2 Objetivos e Desafios da Pesquisa

O objetivo geral deste trabalho é analisar o desempenho de meta-heurísticas bioinspiradas na otimização de rotas de patrulhamento com drones modeladas como TSP-SD-ATP.

Os objetivos específicos são:

- ❑ formalizar a função objetivo baseada em distância euclidiana e penalidade angular dependente da sequência;
- ❑ implementar e comparar GA, PSO e ACO sobre a mesma representação de instância e a mesma função objetivo;
- ❑ usar busca exaustiva como referência ótima nas instâncias pequenas em que a enumeração completa foi executada;
- ❑ implementar um limitante inferior por relaxação do problema de designação para apoiar a análise em instâncias maiores;
- ❑ medir qualidade da solução, tempo de otimização, estabilidade entre sementes e comportamento de convergência;

- ❑ discutir limitações metodológicas associadas a instâncias sintéticas, parâmetros fixos e diferenças de codificação entre métodos.

O principal desafio computacional é combinar duas fontes de complexidade. A primeira é combinatória: a quantidade de rotas cresce fatorialmente com o número de pontos. A segunda é estrutural: o custo de uma transição depende de três nós consecutivos, não apenas da aresta atual. Como consequência, métodos projetados para o TSP clássico precisam ser adaptados para avaliar rotas em um tensor de custos tridimensional.

1.3 Hipótese

A hipótese principal é que meta-heurísticas bioinspiradas conseguem produzir rotas factíveis de baixo *makespan* em instâncias nas quais a busca exaustiva se torna inviável. A hipótese secundária é que a qualidade e o tempo de execução variam substancialmente conforme a forma como cada método representa e explora a dependência de sequência do TSP-SD-ATP.

As perguntas de pesquisa são:

- ❑ Nas instâncias pequenas, qual é o gap das meta-heurísticas em relação ao ótimo obtido por busca exaustiva?
- ❑ Nas 30 instâncias avaliadas, qual método apresenta menor *makespan* mediano?
- ❑ Qual é o custo temporal de obter soluções de melhor qualidade?
- ❑ As diferenças observadas entre GA, PSO e ACO são estatisticamente consistentes quando os métodos são comparados por instância?
- ❑ O limitante inferior por relaxação do problema de designação é informativo para esta variante com penalidade angular?

1.4 Contribuições

As contribuições deste trabalho são:

- ❑ a formulação computacional do TSP-SD-ATP para rotas de patrulhamento com drones, usando tensor 3D de custos;
- ❑ uma implementação em Go de GA, PSO, ACO, busca exaustiva e lower bound por relaxação AP/Hungarian sobre a mesma função objetivo;
- ❑ uma base experimental com 4638 arquivos de resumo, evolução e tempo, cobrindo 30 instâncias e 51 sementes por meta-heurística;

- ❑ a comparação com ótimo exato em 18 instâncias pequenas e com lower bound em todas as 30 instâncias;
- ❑ uma análise empírica e estatística do trade-off entre qualidade de solução e tempo computacional.

1.5 Organização da Dissertação ou Tese

O Capítulo 2 apresenta a fundamentação teórica sobre TSP, custos dependentes da sequência, roteamento com drones e meta-heurísticas bioinspiradas. O Capítulo 3 descreve a formulação adotada, a arquitetura da implementação, os métodos comparados, o lower bound e o pipeline experimental. O Capítulo 4 apresenta a configuração dos experimentos, os resultados, os testes estatísticos e a discussão das limitações. O Capítulo 5 sintetiza as conclusões, contribuições e trabalhos futuros.

Fundamentação Teórica

Este capítulo apresenta os conceitos necessários para compreender a formulação e a comparação experimental desenvolvidas neste trabalho. A Seção 2.1 revisa o TSP clássico e sua dificuldade computacional. A Seção 2.2 discute custos dependentes da sequência e penalidades angulares. A Seção 2.3 situa o problema no contexto de roteamento com drones. As Seções 2.4 a 2.7 apresentam os métodos de otimização usados. A Seção 2.8 descreve a ideia de limitantes inferiores por relaxação, e a Seção 2.9 sintetiza estudos comparativos relacionados.

2.1 Problema do Caixeiro Viajante

O Problema do Caixeiro Viajante define a busca por um ciclo de menor custo que visita cada cidade exatamente uma vez e retorna à cidade inicial. Apesar da formulação simples, o TSP ocupa posição central em otimização combinatória por combinar dificuldade computacional, relevância prática e grande variedade de técnicas de solução (LAWLER et al., 1985; APPLEGATE et al., 2006). A versão de decisão do problema é NP-completa (GAREY; JOHNSON, 1979).

Em uma instância com n nós, fixada a origem, existem $(n - 1)!$ permutações possíveis para a ordem de visita. A busca exaustiva é, portanto, apropriada apenas para instâncias pequenas. Para instâncias maiores, heurísticas e meta-heurísticas buscam soluções de boa qualidade sem percorrer todo o espaço de soluções. A heurística Lin–Kernighan, por exemplo, tornou-se uma referência histórica para o TSP por explorar trocas de arestas de forma eficiente (LIN; KERNIGHAN, 1973).

O TSP clássico costuma ser representado por uma matriz de custos D , na qual d_{ij} indica o custo de ir diretamente do nó i ao nó j . Essa representação pressupõe que o custo de uma aresta independe do caminho percorrido antes dela. O problema deste trabalho rompe essa hipótese: a transição de j para k depende também do nó i visitado imediatamente antes de j .

2.2 Custos Dependentes da Sequência

Custos dependentes de curva aparecem quando o custo de passar por um nó não pode ser descrito apenas por uma aresta de entrada ou saída. Winter (WINTER, 2002) e Vanhove e Fack (VANHOVE; FACK, 2012) discutem modelos de roteamento em que mudanças de direção introduzem custos adicionais. Em missões de drone, essa ideia é relevante porque uma rota com a mesma distância total pode exigir manobras mais abruptas e, portanto, maior tempo efetivo de execução.

Neste trabalho, a dependência de sequência é representada por uma penalidade angular. Dados três nós consecutivos i , j e k , calcula-se o ângulo entre o vetor de chegada $\vec{v}_{i,j}$ e o vetor de saída $\vec{v}_{j,k}$. O custo de transição combina a distância de j para k e uma penalidade normalizada pelo ângulo:

$$c_{i,j,k} = d(j, k) + \frac{\theta(i, j, k)}{\pi}, \quad (1)$$

em que $d(j, k)$ é a distância euclidiana e $\theta(i, j, k)$ é o ângulo, em radianos, entre os dois segmentos. A normalização por π limita a penalidade angular ao intervalo $[0, 1]$: trajetórias quase retilíneas recebem penalidade próxima de zero, enquanto inversões de direção recebem penalidade próxima de um.

Penalidade angular dependente da sequência




Figura 1 – Penalidade angular calculada a partir de três nós consecutivos da rota. Fonte: elaborado pelo autor.

Uma solução é uma permutação $\pi = (\pi_1, \pi_2, \dots, \pi_{n-1})$ dos pontos de interesse, excluindo a base 0. O *makespan* da rota é:

$$f(\pi) = c_{0,0,\pi_1} + \sum_{t=2}^{n-1} c_{\pi_{t-2},\pi_{t-1},\pi_t} + c_{\pi_{n-2},\pi_{n-1},0}. \quad (2)$$

O objetivo é encontrar $\pi^* = \arg \min_{\pi} f(\pi)$. Essa formulação é chamada, neste trabalho, de TSP-SD-ATP. Ela deve ser entendida como uma formulação adotada para este estudo, não como um benchmark consolidado na literatura.

2.3 Roteamento de Drones e Variantes do TSP

O uso de drones em roteamento motivou variantes específicas do TSP. Murray e Chu (MURRAY; CHU, 2015) introduziram o *Flying Sidekick Traveling Salesman Problem*, no qual caminhão e drone cooperam em entregas. Agatz, Bouman e Schmidt (AGATZ; BOUMAN; SCHMIDT, 2018) estudaram formulações e heurísticas para o TSP com drone. Dell’Amico et al. (DELL’AMICO; MONTEMANNI; NOVELLANI, 2021; DELL’AMICO; MONTEMANNI; NOVELLANI, 2022) trataram variantes com múltiplos drones e métodos exatos. Freitas e Penna (FREITAS; PENNA, 2020) propuseram busca em vizinhança variável para o FSTSP.

No patrulhamento com drones, Rajan, Sundar e Gautam (RAJAN; SUNDAR; GAUTAM, 2022) modelaram decisões de roteamento em missões com horizonte finito. O problema desta monografia é mais restrito em número de veículos, pois considera um único drone, mas introduz outra fonte de complexidade: a penalidade angular dependente da sequência. Assim, ele se aproxima do TSP quanto à estrutura de visita única, mas difere do TSP euclidiano por substituir a matriz de arestas por um tensor de transições.

2.4 Busca Exaustiva

A busca exaustiva enumera todas as permutações dos pontos de interesse e avalia cada rota pela função objetivo. Ela é determinística e retorna o ótimo global quando consegue completar a enumeração. Seu custo cresce de forma fatorial, o que limita seu uso a instâncias pequenas. Neste trabalho, a busca exaustiva serve como referência exata nas 18 instâncias executadas de 10 a 15 pontos, identificadas como ‘10a’ a ‘15c’.

2.5 Algoritmos Genéticos

Algoritmos Genéticos são meta-heurísticas populacionais inspiradas em seleção, recombinação e mutação de indivíduos (HOLLAND, 1975; GOLDBERG, 1989). Em problemas de permutação como o TSP, a representação da solução e o operador de cruzamento são decisivos. Potvin (POTVIN, 1996) revisou operadores de crossover para TSP, incluindo operadores que preservam ordem relativa, posição absoluta ou arestas. Larrañaga et al. (nAGA et al., 1999) sistematizaram representações e operadores para o TSP, e Nagata (NAGATA, 2006) propôs o operador EAX, referência de alta qualidade para recombinação baseada em arestas.

Na família de operadores por ordem, o OX preserva a sequência relativa de parte dos pontos e produz filhos que continuam sendo permutações válidas. Essa propriedade é útil quando a função objetivo depende da ordem de visita. Neste trabalho, o GA usa permutação direta dos pontos de interesse, seleção por torneio, crossover OX, mutação por troca e elitismo.

2.6 Otimização por Enxame de Partículas

A Otimização por Enxame de Partículas foi proposta por Kennedy e Eberhart (KENNEDY; EBERHART, 1995) como uma meta-heurística populacional baseada no ajuste de posições por inércia, memória individual e influência social. O PSO original opera em espaços contínuos. Sua aplicação a problemas de permutação exige uma etapa de codificação ou uma redefinição discreta dos operadores.

Clerc (CLERC, 2004) formalizou uma versão discreta do PSO para permutações, tratando velocidades como sequências de transposições. Outra alternativa é usar *random keys*: cada partícula mantém um vetor real e a permutação é obtida pela ordenação dos valores desse vetor (BEAN, 1994). A implementação avaliada nesta monografia adota essa segunda estratégia, pois permite usar a equação contínua clássica do PSO e converter a posição para uma rota factível a cada avaliação.

2.7 Otimização por Colônia de Formigas

A Otimização por Colônia de Formigas modela a construção incremental de soluções por agentes que combinam trilhas de feromônio e informação heurística (DORIGO; MANIEZZO; COLORNI, 1996). O TSP foi uma das primeiras aplicações de referência da ACO (DORIGO; GAMBARDELLA, 1997). Dorigo e Stützle (DORIGO; STÜTZLE, 2004) apresentam o framework da meta-heurística, enquanto Stützle e Hoos (STÜTZLE; HOOS, 2000) propõem o MAX-MIN Ant System, que controla a estagnação por limites nos níveis de feromônio.

No TSP clássico, o feromônio costuma ser associado a arestas. No TSP-SD-ATP, a decisão de visitar o próximo nó depende da tripla anterior–atual–próximo. Por isso, a implementação deste trabalho usa feromônio tridimensional $\tau_{i,j,k}$ e informação heurística $\eta_{i,j,k} = 1/c_{i,j,k}$. Essa escolha preserva a estrutura da função objetivo, mas aumenta o espaço de parâmetros de feromônio em relação a uma ACO bidimensional.

2.8 Limitantes Inferiores e Relaxação por Designação

Um limitante inferior fornece um valor que não excede o ótimo de um problema de minimização. Para o TSP, relaxações baseadas no problema de designação são usadas

para obter bounds que ignoram parte das restrições de conectividade. Neste trabalho, a relaxação AP reduz o tensor tridimensional para uma matriz bidimensional por meio de:

$$c'_{j,k} = \min_i c_{i,j,k}. \quad (3)$$

Como cada entrada reduzida escolhe o menor custo possível entre todos os nós anteriores, a matriz C' não superestima a transição correspondente no problema original. Resolver o problema de designação nessa matriz por algoritmo Hungarian gera um limitante inferior. Esse valor não é necessariamente uma rota factível, pois a solução relaxada pode conter subtours e não preserva todo o contexto angular da sequência.

2.9 Estudos Comparativos

Comparações entre meta-heurísticas no TSP mostram que o desempenho relativo depende da instância, da representação e dos parâmetros. Wu (WU, 2020) comparou GA, PSO e ACO em instâncias TSPLIB e observou vantagem do GA em instâncias de até 100 cidades. Haroun et al. (HAROUN; JAMAL; HICHAM, 2015) relataram vantagem do ACO em qualidade, com maior custo computacional. Chandra e Naro (CHANDRA; NARO, 2022) aplicaram análise estatística a métodos bioinspirados no TSP e identificaram diferenças significativas entre algoritmos. Halim e Ismail (HALIM; ISMAIL, 2019) destacaram que a escolha da representação pode ser tão determinante quanto a escolha da meta-heurística.

O protocolo estatístico adotado nesta monografia segue a recomendação de Demšar (DEMŠAR, 2006) para comparar múltiplos algoritmos sobre múltiplas bases de dados: teste de Friedman, pós-teste de Nemenyi e análise pareada complementar. Essa escolha evita assumir normalidade dos resultados e compara os métodos por postos médios nas instâncias avaliadas.

Formulação do Problema e Métodos

Este capítulo descreve a proposta computacional avaliada nesta monografia. O foco é formalizar o TSP-SD-ATP, apresentar a estrutura de implementação e detalhar como GA, PSO, ACO, busca exaustiva e lower bound foram integrados ao mesmo pipeline experimental. Conforme a orientação do template institucional, a revisão bibliográfica fica concentrada no Capítulo 2; aqui são descritas as escolhas efetivamente implementadas.

3.1 Formulação do Problema

Uma instância é definida por um conjunto de pontos bidimensionais $V = \{0, 1, \dots, n-1\}$. O nó 0 é a base de partida e retorno do drone. Os demais nós, $V' = V \setminus \{0\}$, são pontos de interesse que devem ser visitados exatamente uma vez. Uma rota factível é uma permutação π dos nós de V' .

O diferencial do TSP-SD-ATP está na avaliação da rota. Em vez de uma matriz $D[j][k]$, a implementação usa um tensor 3D $G[anterior][atual][proximo]$. Cada entrada armazena o custo de seguir de ‘atual’ para ‘proximo’ considerando que o nó visitado imediatamente antes foi ‘anterior’. O custo soma distância euclidiana e penalidade angular normalizada, conforme a Equação 1.

A função objetivo percorre a permutação de pontos de interesse, soma a partida da base, as transições internas e o retorno à base. Após a pré-computação do tensor, uma rota é avaliada em $O(n)$, pois cada passo consulta diretamente uma entrada de G . A pré-computação exige $O(n^3)$ entradas, custo aceitável para as instâncias estudadas.

3.2 Arquitetura da Implementação

A implementação foi desenvolvida em Go e organizada em pacotes. O pacote ‘points’ representa os pontos bidimensionais e a geração de instâncias. O pacote ‘graph’ cria o tensor de custos e calcula o *makespan*. O pacote ‘optimization’ contém os métodos de




Figura 2 – Representação do tensor 3D de custos usado para avaliar transições dependentes da sequência. Fonte: elaborado pelo autor.

otimização. O pacote ‘cmd’ expõe a interface de linha de comando baseada em Cobra, e ‘shared/reporting’ registra os resultados estruturados.

O fluxo experimental parte de arquivos ‘points’, gera ou carrega arquivos ‘graph’ e executa um comando de otimização. Cada execução produz três artefatos: um resumo final (‘summary’), um histórico de melhorias (‘evolution’) e uma decomposição temporal (‘timing’). O identificador da execução combina instância, método, semente e hash dos parâmetros, reduzindo o risco de sobrescrever resultados de configurações distintas.

3.3 Algoritmo Genético

No GA, cada indivíduo é uma permutação direta dos pontos de interesse, isto é, dos nós 1 a $n - 1$. A população inicial é gerada aleatoriamente. A cada geração, pais são selecionados por torneio de tamanho 2; o crossover OX produz descendentes preservando a validade da permutação; a mutação *swap* troca dois pontos com probabilidade 0,05; e o elitismo preserva o melhor indivíduo.

Os parâmetros usados nos experimentos são população 100, 100 iterações, elitismo 1, taxa de mutação 0,05 e torneio de tamanho 2. Esses valores foram mantidos fixos para todas as instâncias. A decisão favorece reprodutibilidade e comparação direta, mas não equivale a um ajuste fino por instância.

3.4 Otimização por Enxame de Partículas

O PSO implementado usa *random keys*. Cada partícula mantém um vetor real de dimensão $n - 1$; a rota é obtida ordenando os índices pelo valor correspondente no vetor. Assim, uma atualização contínua de posição e velocidade é convertida em uma permutação factível para avaliação pelo tensor G .

A velocidade é atualizada por:

$$v_{i,d}^{t+1} = wv_{i,d}^t + c_1r_1(p_{i,d} - x_{i,d}^t) + c_2r_2(g_d - x_{i,d}^t), \quad (4)$$

em que $w = 0,7$, $c_1 = 2,0$, $c_2 = 2,0$, p_i é a melhor posição histórica da partícula e g é a melhor posição global. Após a atualização, a posição contínua é reordenada para produzir a rota. A principal limitação dessa codificação é que pequenas mudanças no vetor contínuo podem alterar a permutação de forma não local, o que afeta a exploração de adjacências relevantes para o TSP-SD-ATP.

3.5 Otimização por Colônia de Formigas

No ACO, cada formiga constrói uma rota incrementalmente a partir da base. Como o custo depende de três nós, a estrutura de feromônio também é tridimensional. No estado definido por nó anterior i e nó atual j , a probabilidade de escolher o próximo nó k é proporcional a:

$$p_{i,j,k} \propto [\tau_{i,j,k}]^\alpha [\eta_{i,j,k}]^\beta, \quad (5)$$

em que $\tau_{i,j,k}$ é o feromônio e $\eta_{i,j,k} = 1/G[i][j][k]$ é a informação heurística. A seleção usa roleta proporcional entre os pontos ainda não visitados. Após a construção das rotas, ocorre evaporação global e depósito de feromônio pelas formigas que usaram cada transição.

Os parâmetros usados foram população 100, 100 iterações, $\alpha = 1,0$, $\beta = 2,0$, $\rho = 0,2$ e $Q = 100$. A adaptação por feromônio 3D preserva a dependência de sequência da função objetivo, mas aumenta o número de trilhas de feromônio em relação ao ACO aplicado ao TSP clássico.

3.6 Busca Exaustiva

A busca exaustiva enumera todas as permutações dos pontos de interesse usando o algoritmo de Heap. Para cada permutação, calcula-se o *makespan* pelo mesmo tensor de custos usado pelas meta-heurísticas. O método retorna o ótimo global, mas seu custo fatorial restringe seu uso. No conjunto de dados deste trabalho, a busca exaustiva foi executada nas 18 instâncias de 10 a 15 pontos.

3.7 Lower Bound por Relaxação AP

Além dos métodos que retornam rotas factíveis, foi implementado um lower bound baseado na relaxação do problema de designação. O tensor 3D é reduzido para uma matriz 2D por $c'_{j,k} = \min_i G[i][j][k]$. Em seguida, o problema de designação é resolvido pelo algoritmo Hungarian em $O(n^3)$.

O valor retornado é um limitante inferior: ele não excede o ótimo do TSP-SD-ATP, pois cada transição reduzida escolhe o menor custo possível entre contextos anteriores. Entretanto, a solução do problema de designação pode conter subtours e não representa necessariamente uma rota única que parte da base, visita todos os pontos e retorna. Por isso, o lower bound é usado como referência numérica, não como método concorrente de construção de rotas.

3.8 Pipeline Experimental

O pipeline experimental foi executado sobre 30 instâncias sintéticas, com tamanhos 10, 11, 12, 13, 14, 15, 20, 30, 50 e 100 pontos, três variantes por tamanho. Para GA, PSO e ACO, foram usadas 51 sementes, de 0 a 50. A busca exaustiva tem execução determinística e aparece apenas nas 18 instâncias pequenas. O lower bound também é determinístico e foi executado nas 30 instâncias.

Tabela 1 – Métodos implementados e parâmetros usados nos experimentos.

Método	Representação	Parâmetros principais
Busca exaustiva	Permutação direta	Sem hiperparâmetros; ótimo para ‘10a’–‘15c’
GA	Permutação direta	população=100, iterações=100, elitismo=1, mutação=0,05, torneio=2
PSO	Random keys	população=100, iterações=100, $w = 0,7$, $c_1 = 2,0$, $c_2 = 2,0$
ACO	Feromônio 3D	população=100, iterações=100, $\alpha = 1,0$, $\beta = 2,0$, $\rho = 0,2$, $Q = 100$
Lower bound	Relaxação AP	redução 3D→2D, Hungarian $O(n^3)$

O conjunto final contém 4638 arquivos de resumo: 1530 para GA, 1530 para PSO, 1530 para ACO, 30 para lower bound e 18 para busca exaustiva. A mesma quantidade de arquivos de evolução e de tempo foi registrada, permitindo analisar qualidade final, trajetória de convergência e custo computacional.

Experimentos e Análise dos Resultados

Este capítulo apresenta a avaliação experimental dos métodos descritos no Capítulo 3. A análise usa os arquivos estruturados produzidos pela implementação: 4638 resumos, 4638 históricos de evolução e 4638 arquivos de tempo. Os resultados são discutidos em termos de qualidade da solução, tempo computacional, estabilidade entre sementes, significância estatística e limitações metodológicas.

4.1 Método para a Avaliação

Todas as execuções otimizam a mesma função objetivo: o *makespan* da rota de patrulhamento. Uma solução factível parte da base, visita cada ponto de interesse exatamente uma vez e retorna à base. A avaliação usa o tensor $G[anterior][atual][proximo]$, que incorpora distância euclidiana e penalidade angular.

As instâncias são sintéticas, com coordenadas no intervalo $[-1, 1]$. Foram usados 10 tamanhos de instância: 10, 11, 12, 13, 14, 15, 20, 30, 50 e 100 pontos. Para cada tamanho há três variantes, identificadas por letras ('a', 'b' e 'c'), totalizando 30 instâncias. GA, PSO e ACO foram executados com 51 sementes em cada instância. A busca exaustiva foi executada nas 18 instâncias de 10 a 15 pontos. O lower bound AP foi executado em todas as 30 instâncias.

As métricas principais são:

- ❑ **makespan**: valor final da função objetivo;
- ❑ **gap vs. ótimo**: diferença percentual em relação à busca exaustiva, nas 18 instâncias com ótimo conhecido;
- ❑ **gap vs. lower bound**: diferença percentual em relação ao limitante AP;
- ❑ **tempo de otimização**: duração da etapa de otimização em milissegundos;
- ❑ **taxa de acerto**: proporção de sementes que alcançam o ótimo nas instâncias com busca exaustiva.

Tabela 2 – Cobertura experimental dos métodos avaliados.

Método	Runs	Instâncias	Sementes
ACO	1530	30	51
GA	1530	30	51
PSO	1530	30	51
Lower bound	30	30	1
Busca exaustiva	18	18	1

4.2 Experimentos

Os experimentos foram executados por uma interface de linha de comando em Go. Cada execução recebe o arquivo de instância, o método, a semente e o diretório de resultados. O identificador da execução é usado para nomear os arquivos de resumo, evolução e tempo. Para as meta-heurísticas, os parâmetros foram mantidos fixos: população 100 e 100 iterações. Essa decisão permite comparar os métodos sob o mesmo orçamento populacional, mas não substitui uma análise de sensibilidade de hiperparâmetros.

A busca exaustiva fornece o ótimo global nas instâncias em que foi executada. A Tabela 3 apresenta esses valores. Eles são usados como referência para calcular o gap das meta-heurísticas nas instâncias pequenas.

Tabela 3 – Ótimos obtidos por busca exaustiva nas 18 instâncias pequenas.

Instância	Ótimo	Instância	Ótimo	Instância	Ótimo
10a	8,251	12a	9,501	14a	11,557
10b	7,906	12b	9,769	14b	11,467
10c	9,545	12c	10,480	14c	11,486
11a	9,493	13a	10,950	15a	9,129
11b	8,823	13b	11,474	15b	12,185
11c	10,260	13c	10,042	15c	12,160

4.3 Avaliação dos Resultados

4.3.1 Qualidade nas Instâncias com Ótimo Conhecido

Nas 18 instâncias com busca exaustiva, o ACO apresentou o menor gap médio em relação ao ótimo. A Tabela 4 resume os resultados agregados sobre 918 execuções por método nesse subconjunto. O ACO obteve gap médio de 0,4296% e taxa global de acerto de 71,79%. O GA obteve gap médio de 5,2814% e taxa de acerto de 26,47%. O PSO obteve gap médio de 22,2915% e taxa de acerto de 4,25%.

Tabela 4 – Gap percentual em relação ao ótimo nas instâncias ‘10a’–‘15c’.

Método	Runs	Gap médio	Gap mín.	Gap máx.	Taxa de acerto
ACO	918	0,4296%	0,0000%	9,4445%	71,79%
GA	918	5,2814%	0,0000%	41,4267%	26,47%
PSO	918	22,2915%	0,0000%	76,5549%	4,25%

Gap mediano vs brute-force (%)

	ACO	GA	PSO	LB
10a	0.00%	0.00%	14.30%	-41.11%
10b	0.00%	3.54%	7.92%	-62.32%
10c	0.00%	0.00%	14.64%	-48.07%
11a	0.00%	0.78%	12.58%	-52.29%
11b	0.00%	6.61%	15.46%	-52.86%
11c	0.00%	0.00%	14.28%	-40.79%
12a	0.00%	0.00%	23.99%	-52.12%
12b	0.00%	2.27%	20.41%	-58.12%
12c	0.93%	1.82%	14.45%	-60.98%
13a	0.00%	5.84%	20.93%	-47.04%
13b	0.00%	4.44%	21.44%	-47.02%
13c	0.00%	6.55%	34.66%	-46.75%
14a	0.58%	5.06%	23.56%	-65.35%
14b	0.10%	7.31%	18.74%	-50.51%
14c	0.00%	6.28%	29.00%	-44.10%
15a	0.00%	15.73%	51.89%	-48.33%
15b	1.88%	11.57%	34.63%	-49.92%
15c	4.13%	3.92%	29.84%	-56.75%

Figura 3 – Gap em relação à busca exaustiva nas instâncias com ótimo conhecido. Fonte: dados de ‘src/data/results/’.

Taxa de sucesso: encontrou o ótimo (%)

	ACO	GA	PSO	LB
10a	100.0%	51.0%	9.8%	0.0%
10b	74.5%	45.1%	9.8%	0.0%
10c	100.0%	80.4%	29.4%	0.0%
11a	100.0%	11.8%	3.9%	0.0%
11b	58.8%	35.3%	5.9%	0.0%
11c	100.0%	51.0%	5.9%	0.0%
12a	100.0%	58.8%	5.9%	0.0%
12b	100.0%	13.7%	2.0%	0.0%
12c	39.2%	31.4%	3.9%	0.0%
13a	78.4%	17.6%	0.0%	0.0%
13b	90.2%	19.6%	0.0%	0.0%
13c	98.0%	17.6%	0.0%	0.0%
14a	7.8%	0.0%	0.0%	0.0%
14b	25.5%	2.0%	0.0%	0.0%
14c	80.4%	5.9%	0.0%	0.0%
15a	84.3%	9.8%	0.0%	0.0%
15b	31.4%	19.6%	0.0%	0.0%
15c	23.5%	5.9%	0.0%	0.0%

Figura 4 – Taxa de acerto do ótimo por método nas instâncias pequenas. Fonte: dados de ‘src/data/results/’.

4.3.2 Qualidade nas Instâncias Maiores

Para instâncias acima de 15 pontos, a busca exaustiva não foi usada como ótimo de referência. A análise passa a comparar as meta-heurísticas entre si e com o lower bound. Nas instâncias de 50 e 100 pontos, o ACO apresentou *makespan* médio substancialmente menor que GA e PSO, como mostra a Tabela 5. Em ‘100a’, por exemplo, a média do ACO foi 45,3528, enquanto GA e PSO obtiveram 110,6608 e 136,5131, respectivamente.

Esse resultado favorece a interpretação de que a construção probabilística com feromônio tridimensional aproveitou melhor a estrutura de dependência de sequência do problema. A interpretação deve ser delimitada: ela vale para a implementação, os parâmetros e as instâncias avaliadas. Não demonstra que ACO domina GA ou PSO em todas as variantes de TSP ou em todos os cenários de patrulha.

Makespan mediano por instancia e metodo

	ACO	GA	PSO	LB
10a	8.25	8.25	9.43	4.86
10b	7.91	8.19	8.53	2.98
10c	9.55	9.55	10.94	4.96
11a	9.49	9.57	10.69	4.53
11b	8.82	9.41	10.19	4.16
11c	10.26	10.26	11.73	6.08
12a	9.50	9.50	11.78	4.55
12b	9.77	9.99	11.76	4.09
12c	10.58	10.67	11.99	4.09
13a	10.95	11.59	13.24	5.80
13b	11.47	11.98	13.93	6.08
13c	10.04	10.70	13.52	5.35
14a	11.62	12.14	14.28	4.00
14b	11.48	12.31	13.62	5.68
14c	11.49	12.21	14.82	6.42
15a	9.13	10.56	13.87	4.72
15b	12.41	13.60	16.40	6.10
15c	12.66	12.64	15.79	5.26
20a	13.93	16.19	21.85	6.82
20b	14.50	16.56	22.46	6.61
20c	14.31	16.61	21.18	6.14
30a	17.46	25.81	35.48	7.50
30b	17.95	25.40	33.91	8.07
30c	18.08	25.95	34.80	7.28
50a	25.66	44.81	59.90	7.56
50b	27.50	48.23	64.52	9.21
50c	26.99	46.93	62.26	9.24
100a	45.40	110.63	136.43	13.12
100b	48.15	111.38	135.93	13.47
100c	47.06	110.92	139.25	12.02

Figura 5 – Makespan mediano por instância e método nas 30 instâncias avaliadas. Fonte: dados de 'src/data/results/'.

Tabela 5 – Melhor e média de makespan nas instâncias de 50 e 100 pontos.

Instância	ACO best	ACO média	GA best	GA média	PSO best	PSO média
50a	24,6688	25,6475	41,0120	45,3925	53,7651	59,7284
50b	26,3528	27,4843	42,6487	48,6345	57,0330	64,3194
50c	26,2372	27,0062	42,0122	46,9438	54,4114	62,3455
100a	42,6718	45,3528	97,5921	110,6608	127,4034	136,5131
100b	45,4689	48,0596	97,5343	110,4959	126,3967	135,9987
100c	45,4858	46,9487	95,1632	111,3243	126,1838	138,1908

4.3.3 Lower Bound AP

O lower bound AP foi válido nas 18 instâncias com ótimo conhecido: em todos os casos, o valor do bound foi menor ou igual ao ótimo por busca exaustiva. Entretanto, o bound foi frouxo. O gap médio entre o lower bound e o ótimo foi 51,36%, com mínimo de 40,79% e máximo de 65,35%.

Tabela 6 – Resumo do gap entre lower bound AP e ótimo por busca exaustiva.

Métrica	Valor
Gap médio LB→BF	51,36%
Gap mínimo	40,79%
Gap máximo	65,35%
Instâncias avaliadas	18
Violações $LB \leq BF$	0

A frouxidão é esperada: a redução $c'_{j,k} = \min_i G[i][j][k]$ remove parte do contexto angular, escolhendo para cada transição o melhor nó anterior possível. Isso torna o bound barato e válido, mas pouco informativo como aproximação do ótimo do TSP-SD-ATP.

4.3.4 Tempo Computacional

O ganho de qualidade do ACO vem acompanhado de maior custo computacional. Nas instâncias de 100 pontos, o tempo médio de otimização do ACO ficou em torno de 4,26 segundos, enquanto o GA ficou entre 36 e 39 milissegundos e o PSO entre 73 e 76 milissegundos. A Tabela 7 mostra as razões por instância.

Tabela 7 – Tempo médio de otimização em instâncias de 100 pontos.

Instância	ACO ms	GA ms	PSO ms	ACO/GA	ACO/PSO
100a	4262,06	38,82	76,24	109,78x	55,91x
100b	4276,55	36,27	75,25	117,89x	56,83x
100c	4266,55	39,37	73,84	108,37x	57,78x

Para patrulhamento com drones, esse trade-off é central. Se a rota puder ser planejada offline, o ACO pode ser preferível pela qualidade. Se a rota precisar ser recalculada rapidamente, o GA oferece uma alternativa muito mais barata, embora com makespan médio maior nas instâncias avaliadas.




Figura 6 – Escalabilidade temporal dos métodos por tamanho de instância. Fonte: dados de ‘src/data/results/timing/’.




Figura 7 – Trade-off entre qualidade de solução e tempo de otimização. Fonte: dados de ‘src/data/results/’.

4.3.5 Estabilidade e Convergência

A variabilidade entre sementes também difere entre os métodos. O ACO apresentou boa qualidade média e estabilidade nas instâncias grandes, mas com custo temporal elevado. O GA foi rápido, porém produziu soluções de maior makespan médio. O PSO teve o pior desempenho de qualidade neste desenho experimental, resultado compatível com a limitação da codificação por *random keys*: a ordenação de valores contínuos nem sempre preserva adjacências úteis para uma rota com custos de tripletas.




Figura 8 – Distribuição do makespan por método e tamanho, considerando as sementes estocásticas. Fonte: dados de ‘src/data/results/’.

4.3.6 Análise Estatística

A comparação estatística seguiu Demšar (DEMŠAR, 2006). Para cada uma das 30 instâncias, foi calculada a mediana do makespan por método; em seguida, os métodos foram ranqueados por instância. O teste de Friedman com correção de Iman–Davenport rejeitou a hipótese nula de equivalência entre os métodos: $F(2, 58) = 293,2222$, com $p = 4,710129 \times 10^{-31}$.

Os ranks médios foram ACO=1,1000, GA=1,9000 e PSO=3,0000. O pós-teste de Nemenyi, com diferença crítica $CD = 0,6050$ para $\alpha = 0,05$, indicou diferença significativa nos três pares: ACO–GA, ACO–PSO e GA–PSO. O teste de Wilcoxon pareado com correção de Bonferroni–Holm também rejeitou a hipótese nula nos três pares.

Figura 2. Trade-off entre tempo, qualidade e convergência

Afiniação: o ACO troca maior qualidade de solução por tempo de convergência substancialmente maior.




Figura 9 – Comportamento agregado de convergência dos métodos ao longo das execuções. Fonte: dados de evolução em ‘src/data/results/evolution/’.




Figura 10 – Diagrama de diferença crítica para os ranks médios de makespan. Fonte: ‘scripts/analise-estatistica.py’.

4.3.7 Limitações Metodológicas

Os resultados devem ser interpretados dentro do desenho experimental. Primeiro, as instâncias são sintéticas e geradas em um plano normalizado; elas não capturam obstáculos, vento, autonomia de bateria, zonas proibidas ou prioridades reais de patrulha. Segundo, os hiperparâmetros foram fixados para todos os métodos. ACO, GA e PSO poderiam ter desempenho diferente sob ajuste sistemático por instância. Terceiro, os métodos não usam a mesma codificação: GA usa permutação direta, PSO usa *random keys*, e ACO constrói rotas por transições probabilísticas tridimensionais. Essa diferença é parte do desenho comparativo, mas limita inferências causais sobre a superioridade intrínseca de uma meta-heurística.

Por fim, a busca exaustiva cobre apenas as instâncias ‘10a’ a ‘15c’. Para instâncias

maiores, não há ótimo conhecido. O lower bound AP ajuda a oferecer uma referência, mas sua frouxidão impede tratá-lo como aproximação apertada do ótimo. As conclusões, portanto, descrevem o desempenho observado nas implementações e instâncias avaliadas, não uma ordenação universal entre GA, PSO e ACO.

Conclusão

Este trabalho investigou a otimização de rotas de patrulhamento com drones por meio do TSP-SD-ATP, uma formulação em que o custo de transição depende da sequência anterior–atual–próximo e inclui penalidade angular. Foram implementados e avaliados GA, PSO, ACO, busca exaustiva e um lower bound por relaxação AP/Hungarian. A avaliação usou 30 instâncias sintéticas, 51 sementes por meta-heurística e 4638 arquivos estruturados de resumo, evolução e tempo.

5.1 Principais Contribuições

A primeira contribuição foi a formalização computacional do TSP-SD-ATP com tensor 3D de custos. Essa representação permite avaliar rotas considerando distância e penalidade angular, diferenciando o problema do TSP euclidiano clássico. Após a pré-computação do tensor, a avaliação de uma rota é linear no número de pontos.

A segunda contribuição foi a implementação comparativa de métodos distintos sobre a mesma função objetivo. O GA usa permutação direta, OX, mutação *swap*, torneio e elitismo. O PSO usa *random keys*. O ACO usa feromônio 3D e heurística local baseada em $1/G[i][j][k]$. A busca exaustiva fornece ótimos para as instâncias pequenas, e o lower bound AP fornece referência inferior para todas as instâncias.

A terceira contribuição foi a análise experimental. Nas 18 instâncias com ótimo conhecido, o ACO apresentou gap médio de 0,4296% e taxa global de acerto de 71,79%. O GA obteve gap médio de 5,2814%, e o PSO 22,2915%. Nas instâncias de 50 e 100 pontos, o ACO manteve makespan médio substancialmente menor que GA e PSO. A análise estatística por Friedman/Iman–Davenport, Nemenyi e Wilcoxon/Holm indicou diferenças significativas entre os três métodos, com ranks médios ACO=1,1000, GA=1,9000 e PSO=3,0000.

O principal trade-off observado foi qualidade versus tempo. Em instâncias de 100 pontos, o ACO levou em média cerca de 4,26 segundos de otimização, enquanto o GA ficou abaixo de 40 milissegundos e o PSO abaixo de 77 milissegundos. Assim, o ACO foi

o método de melhor qualidade no desenho experimental, mas o GA foi muito mais rápido. O PSO teve desempenho inferior em qualidade, resultado delimitado à implementação por *random keys* e aos parâmetros usados.

O lower bound AP foi válido, mas frouxo. Nas 18 instâncias com busca exaustiva, ele nunca excedeu o ótimo, mas apresentou gap médio de 51,36%. Esse resultado confirma sua utilidade como referência inferior barata e, ao mesmo tempo, mostra que a redução 3D→2D perde informação angular relevante.

5.2 Limitações

As conclusões deste trabalho são limitadas por quatro fatores. Primeiro, as instâncias são sintéticas e bidimensionais; cenários reais de patrulha podem incluir obstáculos, zonas proibidas, vento, restrições de bateria e prioridades temporais. Segundo, os parâmetros das meta-heurísticas foram fixados, sem tuning sistemático. Terceiro, os métodos usam codificações distintas, o que torna a comparação prática, mas não isola completamente o efeito da meta-heurística em relação ao efeito da representação. Quarto, a busca exaustiva cobre apenas as instâncias de 10 a 15 pontos; para instâncias maiores, a análise depende de comparação relativa e de um lower bound frouxo.

Essas limitações não invalidam os achados, mas delimitam seu alcance. ACO foi melhor em qualidade nas condições avaliadas; GA foi melhor em tempo; PSO foi inferior nesta implementação. Não se conclui que essa ordenação seja universal para todos os problemas de roteamento com drones ou para todas as parametrizações possíveis.

5.3 Trabalhos Futuros

Trabalhos futuros podem seguir cinco direções. A primeira é realizar análise de sensibilidade e tuning de hiperparâmetros, especialmente para ACO, cujo desempenho depende de α , β , ρ e Q . A segunda é testar variantes mais fortes dos métodos, como MMAS para ACO, EAX ou busca local 2-opt/3-opt para GA, e PSO discreto baseado em operadores de troca.

A terceira direção é construir instâncias baseadas em cenários reais de patrulha, com mapas geográficos, obstáculos, zonas de risco e restrições de autonomia. A quarta é estender o modelo para múltiplos drones, aproximando-o de variantes de mTSP e problemas de roteamento com frota. A quinta é investigar métodos híbridos e neurais, como DeepACO, NeuFACO e abordagens que combinam aprendizado profundo com construção probabilística de rotas (YE et al., 2023; YE et al., 2025; LIU; CHEN; ZHANG, 2025).

Também há espaço para desenvolver lower bounds mais apertados para o TSP-SD-ATP. O bound AP implementado é barato e válido, mas perde contexto ao reduzir o

tensor 3D para matriz 2D. Relaxações que preservem mais informação de sequência podem fornecer referências melhores para instâncias grandes.

5.4 Contribuições em Produção Bibliográfica

Até a finalização desta monografia, a principal produção associada ao trabalho é a base de código e dados experimentais do projeto. O repositório contém a implementação em Go, os scripts de execução, os resultados estruturados, as figuras de análise e o texto da monografia. Publicações acadêmicas derivadas podem explorar a formulação TSP-SD-ATP, a comparação entre métodos e a construção de bounds mais informativos para custos dependentes da sequência.

Referências

- AGATZ, N.; BOUMAN, P.; SCHMIDT, M. Optimization approaches for the traveling salesman problem with drone. **Transportation Science**, v. 52, n. 4, p. 965–981, 2018.
- APPLEGATE, D. L. et al. **The Traveling Salesman Problem: A Computational Study**. Princeton: Princeton University Press, 2006.
- BEAN, J. C. Genetic algorithms and random keys for sequencing and optimization. **ORSA Journal on Computing**, v. 6, n. 2, p. 154–160, 1994.
- CHANDRA, A.; NARO, A. A comparative study of metaheuristics methods for solving traveling salesman problem. **International Journal of Information Science and Technology**, v. 6, n. 2, p. 1–7, 2022.
- CLERC, M. Discrete particle swarm optimization, illustrated by the traveling salesman problem. In: ONWUBOLU, G. C.; BABU, B. V. (Ed.). **New Optimization Techniques in Engineering**. [S.l.]: Springer, 2004. (Studies in Fuzziness and Soft Computing, v. 141), p. 219–239.
- DELL’AMICO, M.; MONTEMANNI, R.; NOVELLANI, S. Modeling the flying sidekick traveling salesman problem with multiple drones. **Networks**, v. 78, n. 3, p. 303–327, 2021.
- _____. Exact models for the flying sidekick traveling salesman problem. **International Transactions in Operational Research**, v. 29, n. 3, p. 1360–1393, 2022.
- DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. **Journal of Machine Learning Research**, v. 7, p. 1–30, 2006.
- DORIGO, M.; GAMBARDELLA, L. M. Ant colonies for the travelling salesman problem. **BioSystems**, v. 43, n. 2, p. 73–81, 1997.
- DORIGO, M.; MANIEZZO, V.; COLORNI, A. Ant system: Optimization by a colony of cooperating agents. **IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics**, v. 26, n. 1, p. 29–41, 1996.
- DORIGO, M.; STÜTZLE, T. **Ant Colony Optimization**. Cambridge: MIT Press, 2004.

- FREITAS, J. C. de; PENNA, P. H. V. A variable neighborhood search for flying sidekick traveling salesman problem. **International Transactions in Operational Research**, v. 27, n. 1, p. 267–290, 2020.
- GAREY, M. R.; JOHNSON, D. S. **Computers and Intractability: A Guide to the Theory of NP-Completeness**. San Francisco: W. H. Freeman, 1979.
- GOLDBERG, D. E. **Genetic Algorithms in Search, Optimization, and Machine Learning**. Reading: Addison-Wesley, 1989.
- HALIM, A. H.; ISMAIL, I. Combinatorial optimization: Comparison of heuristic algorithms in travelling salesman problem. **Archives of Computational Methods in Engineering**, v. 26, n. 2, p. 367–380, 2019.
- HAROUN, S. A.; JAMAL, B.; HICHAM, E. H. A performance comparison of GA and ACO applied to TSP. **International Journal of Computer Applications**, v. 117, n. 20, p. 28–35, 2015.
- HOLLAND, J. H. **Adaptation in Natural and Artificial Systems**. Ann Arbor: University of Michigan Press, 1975.
- KENNEDY, J.; EBERHART, R. C. Particle swarm optimization. In: **Proceedings of ICNN'95 – International Conference on Neural Networks**. [S.l.]: IEEE, 1995. p. 1942–1948.
- LAWLER, E. L. et al. (Ed.). **The Traveling Salesman Problem: A Guided Tour of Combinatorial Optimization**. New York: Wiley, 1985.
- LIN, S.; KERNIGHAN, B. W. An effective heuristic algorithm for the traveling-salesman problem. **Operations Research**, v. 21, n. 2, p. 498–516, 1973.
- LIU, X.; CHEN, Y.; ZHANG, M. Automated design of state transition rules in ant colony optimization by genetic programming. **Memetic Computing**, 2025.
- MURRAY, C. C.; CHU, A. G. The flying sidekick traveling salesman problem: Optimization of drone-assisted parcel delivery. **Transportation Research Part C: Emerging Technologies**, v. 54, p. 86–109, 2015.
- nAGA, P. L. et al. Genetic algorithms for the travelling salesman problem: A review of representations and operators. **Artificial Intelligence Review**, v. 13, n. 2, p. 129–170, 1999.
- NAGATA, Y. Edge assembly crossover for the traveling salesman problem. In: **Proceedings of the 6th European Conference on Evolutionary Computation in Combinatorial Optimization (EvoCOP 2006)**. [S.l.]: Springer, 2006. (LNCS, v. 3906), p. 146–158.
- POTVIN, J.-Y. Genetic algorithms for the traveling salesman problem. **Annals of Operations Research**, v. 63, n. 3, p. 337–370, 1996.
- RAJAN, S.; SUNDAR, K.; GAUTAM, N. Routing problem for unmanned aerial vehicle patrolling missions – a progressive hedging algorithm. **Computers & Operations Research**, v. 142, p. 105702, 2022.

- STÜTZLE, T.; HOOS, H. H. MAX-MIN ant system. **Future Generation Computer Systems**, v. 16, n. 8, p. 889–914, 2000.
- VANHOVE, S.; FACK, V. Route planning with turn restrictions: A computational experiment. **Operations Research Letters**, v. 40, n. 5, p. 342–348, 2012.
- WINTER, S. Modeling costs of turns in route planning. **GeoInformatica**, v. 6, n. 4, p. 345–360, 2002.
- WU, Z. A comparative study of solving traveling salesman problem with genetic algorithm, ant colony algorithm, and particle swarm optimization. In: **Proceedings of the 2020 2nd International Conference on Robotics Systems and Vehicle Technology (RSVT '20)**. [S.l.]: ACM, 2020. p. 95–99.
- YE, H. et al. DeepACO: Neural-enhanced ant colony optimization for combinatorial optimization. **arXiv preprint arXiv:2309.14032**, 2023.
- _____. NeuFACO: Neural focused ant colony optimization for traveling salesman problem. **arXiv preprint arXiv:2503.08812**, 2025.

Apêndices

Anexos

